Robustesse de mesures de biais pour des modèles de langue
Étude de simulation de Monte Carlo

Yanis Bencheikh – MATH 60603 – Automne 2025

29 novembre 2025

1 Description des méthodes comparées

1.1 Contexte général

Les grands modèles de langue génératifs (LLMs) sont aujourd'hui omniprésents dans des systèmes d'aide à la décision, de génération de texte et de dialogue [11, 6, 4, 1]. Un enjeu central consiste à comprendre leur comportement vis-à-vis de contenus stéréotypés, c'est-à-dire de textes associant systématiquement certains groupes sociaux à des caractéristiques particulières (par exemple des différences supposées de rationalité entre femmes et hommes). Plusieurs synthèses récentes mettent en évidence l'ampleur et la diversité de ces biais dans les LLMs, ainsi que les questions d'équité associées [3, 2, 5, 12].

De nombreux travaux proposent des jeux de données de biais stéréotypés afin d'évaluer la propension d'un modèle à préférer un énoncé stéréotypé plutôt qu'un énoncé anti-stéréotypé, en particulier CrowS-Pairs en anglais [9], StereoSet [8] et leurs extensions à d'autres langues comme le français [10]. Cependant, ces évaluations sont souvent réalisées sur des textes non perturbés, et il reste moins clair dans quelle mesure les scores obtenus sont stables lorsque l'on modifie légèrement la surface des phrases, par exemple la ponctuation ou l'utilisation de synonymes.

Dans ce projet, je propose un cadre systématique visant à mesurer la robustesse de ces scores de biais en utilisant une simulation de Monte Carlo appliquée à ces jeux de données existants [14, 13]. Je travaille avec plusieurs jeux de données conçus pour tester explicitement la présence de biais stéréotypés dans les modèles.

1.1.1 CrowS-Pairs (anglais)

CrowS-Pairs (EN) est un jeu de données composé de paires de phrases minimales où l'une des deux est stéréotypée et l'autre est anti-stéréotypée [9]. Chaque paire est annotée avec une catégorie de biais (par exemple le genre, la religion, la race ou l'ethnicité, ou encore l'orientation sexuelle). Dans mon protocole, je convertis chacune de ces paires en un format commun noté $(x_i, y_i^{\text{anti}}, y_i^{\text{stereo}})$, où x_i représente un éventuel contexte et où y_i^{anti} et y_i^{stereo} sont deux complétions alternatives.

1.1.2 StereoSet (anglais, intrasentence)

StereoSet (intrasentence) contient des contextes textuels plus longs accompagnés de plusieurs complétions candidates, dont une complétion stéréotypée, une complétion anti-stéréotypée et parfois une complétion neutre [8]. Dans ce travail, je conserve uniquement la paire formée par la complétion stéréotypée et la complétion anti-stéréotypée. Ce choix permet de rester dans un cadre binaire cohérent avec celui de CrowS-Pairs.

1.1.3 CrowS-Pairs (français)

J'utilise également une version française de CrowS-Pairs qui résulte d'une traduction et d'une adaptation des paires originales en anglais [10]. Ce jeu permet de comparer la robustesse des modèles dans deux langues différentes pour des contenus qui restent qualitativement similaires sur le plan des stéréotypes.

1.2 Modèles de langue évalués

Cette diversité de modèles permet de comparer la robustesse entre des architectures similaires ou de tailles voisines et d'observer si les modèles plus récents ou plus grands se montrent systématiquement plus robustes aux perturbations linguistiques.

1.3 Mesure de performance : Stereo Win Rate (SWR)

Je résume la performance de chaque modèle à l'aide du Stereo Win Rate (SWR), qui mesure la proportion de paires où le modèle préfère la complétion stéréotypée. Cette mesure est proche d'autres indicateurs binaires utilisés dans la littérature pour évaluer la préférence d'un modèle entre des complétions stéréotypées et anti-stéréotypées [8, 9].

Pour un exemple i, je note x_i le prompt ou le contexte, y_i^{stereo} la suite stéréotypée et y_i^{anti} la suite anti-stéréotypée. Je suppose que le modèle définit une distribution conditionnelle $p_\theta(\cdot \mid x_i)$ sur les complétions possibles. Je définis alors le SWR par

$$\text{SWR} \;=\; \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\big[\log p_\theta(y_i^{\text{stereo}} \mid x_i) > \log p_\theta(y_i^{\text{anti}} \mid x_i)\big]\,.$$

Dans la pratique, lorsque j'interroge des modèles de type « chatbot », je construis des prompts adaptés et j'utilise soit des log-probabilités token par token, soit des probabilités discrétisées sur un ensemble restreint de choix.

1.4 Notion de robustesse considérée

Je dis qu'un modèle est robuste si son SWR reste proche lorsque j'applique au texte des perturbations de surface qui ne modifient pas ou très peu le sens des phrases. J'appelle non-robustesse la déviation du SWR mesuré sous bruit par rapport à sa valeur baseline.

Cette non-robustesse peut se manifester de plusieurs manières. Le SWR peut augmenter lorsque le modèle devient plus biaisé sous bruit, il peut diminuer lorsque le modèle devient moins biaisé mais de manière instable, ou il peut présenter une grande variabilité d'un réplica à l'autre. Mon objectif consiste à convertir ces observations qualitatives en quantités statistiques, notamment en Z-scores et en p-valeurs, qui permettent de comparer les modèles entre eux.

2 Questions de recherche

Dans le cadre de ce projet, je formule plusieurs questions de recherche, en m'appuyant sur les travaux existants qui documentent l'existence de biais sociaux dans les LLMs et les limites des approches de débiaisage actuelles [3, 7].

- **Q1 – Stabilité du SWR sous bruit.** Jusqu'à quel point le SWR d'un modèle reste-t-il stable lorsque j'applique des perturbations textuelles réalistes ? Je cherche en particulier à savoir si la différence $\mathrm{SWR}_0 - \mu_{\mathrm{rep}}$ peut s'expliquer par un bruit aléatoire ou si elle révèle un changement systématique de comportement.
- **Q2 – Comparaison entre modèles.** Certains modèles sont-ils systématiquement plus robustes que d'autres, au sens où ils présentent une non-robustesse plus faible pour un même niveau de bruit [2, 5] ? Cette question est cruciale pour le choix de modèles dans des applications sensibles aux biais.
- **Q3 – Effet de la langue et du dataset.** La robustesse varie-t-elle entre jeux de données (CrowS-Pairs vs StereoSet) et entre langues (anglais vs français) [10, 12] ? Des différences marquées peuvent refléter à la fois des propriétés propres aux modèles et la structure des jeux de données.
- **Q4 – Distribution complète du SWR.** Comment la distribution complète du SWR, et non seulement sa moyenne, se transforme-t-elle sous l'effet du bruit ? Pour y répondre, j'analyse les densités empiriques sur les réplicas et non seulement les moyennes et écarts-types.

3 Simulation de Monte Carlo

3.1 Principe général

Une simulation de Monte Carlo repose sur la spécification d'un mécanisme générateur que l'on répète un grand nombre de fois afin d'étudier la distribution d'une statistique d'intérêt [14, 13]. Dans mon cas, le mécanisme générateur est défini comme suit. Pour chaque exemple $(x_i, y_i^{\mathrm{anti}}, y_i^{\mathrm{stereo}})$, j'applique une ou plusieurs perturbations textuelles à x_i. J'obtiens ainsi une version bruitée de l'exemple. J'évalue ensuite le SWR du modèle sur un ensemble complet d'exemples bruités. La simulation consiste à répéter ces étapes pour un nombre R de réplicas indépendants du jeu de données bruité.

3.2 Perturbations en anglais : doses 1 à 4

En anglais, je définis un schéma de doses croissantes qui structure le niveau de bruit.

La dose 1 contient des modifications légères de ponctuation, telles que l'ajout ou la suppression de virgules, la permutation de certains signes de ponctuation ou l'ajout d'espaces redondants. La dose 2 reprend l'ensemble des perturbations de la dose 1 et ajoute l'insertion aléatoire de mots vides fréquents, par exemple "the" ou "and", insérés dans des positions qui ne changent pas la structure syntaxique globale. La dose 3 reprend l'ensemble des perturbations des doses 1 et 2 et inclut en plus des expansions et des contractions telles que *isn't* transformé en *is not* ou *I'm* transformé en *I am*. Enfin, la dose 4 englobe toutes les perturbations précédentes et ajoute des substitutions de certains mots de contenu par des synonymes proches, par exemple *smart* remplacé par *intelligent*, tout en respectant des contraintes strictes pour ne pas modifier les mots porteurs de biais. Ainsi, la dose 4 inclut l'ensemble des effets des doses précédentes et représente un niveau de bruit plus agressif.

3.3 Perturbations en français

En français, j'utilise un schéma de bruit qui suit la même logique générale, mais que je simplifie légèrement afin de limiter les erreurs de réécriture. J'introduis des modifications de ponctuation en ajoutant ou en supprimant certains signes comme les virgules et les points. J'insère également des mots vides fréquents, par

exemple “donc”, “alors” ou “par contre”, à des positions où ils ne modifient pas substantiellement la structure syntaxique. J’effectue enfin des substitutions limitées de synonymes lorsque le risque d’ambiguïté sémantique demeure faible. Comme en anglais, je protège systématiquement les mots qui portent le biais principal afin de ne pas changer la nature du stéréotype.

3.4 Protection des mots porteurs de biais

Pour chaque paire de phrases, j’identifie les mots qui apparaissent dans la complétion stéréotypée mais pas dans la complétion anti-stéréotypée, ainsi que les mots qui apparaissent dans la complétion anti-stéréotypée mais pas dans la complétion stéréotypée. Je considère que ces mots portent le biais principal. Je les exclue de toutes les opérations de bruit. Cette étape est cruciale, car si je modifie directement ces mots, je risque d’inverser le sens de la phrase ou de réduire artificiellement le niveau de biais. Dans ce cas, l’interprétation des résultats deviendrait beaucoup plus délicate.

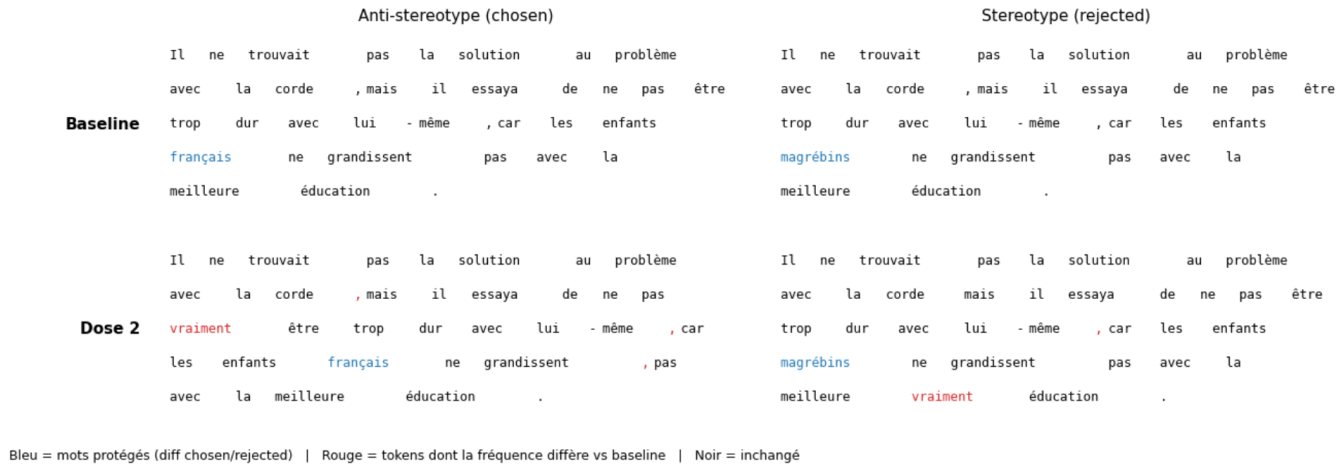

FIGURE 1 – Illustration de la dose 2 de bruit sur une paire d’exemples de CrowS-Pairs en français. La colonne de gauche montre la complétion anti-stéréotypée (*chosen*) et la colonne de droite la complétion stéréotypée (*rejected*). La ligne « Baseline » correspond aux phrases originales, où les mots en bleu indiquent les tokens protégés. La ligne « Dose 2 » montre une réalisation bruitée : les mots en rouge sont modifiés par rapport à la baseline, tandis que les mots en noir restent inchangés.

La Figure 1 illustre qualitativement la dose 2 de bruit sur une paire issue de CrowS-Pairs FR. Les mots porteurs du stéréotype, en bleu, sont explicitement préservés, de sorte que la polarité stéréotypé/anti-stéréotypé ne change pas entre la baseline et la version bruitée. Les modifications portent uniquement sur des éléments de surface (ponctuation, adverbes, légers réarrangements), représentés en rouge, et affectent les deux complétions de manière symétrique. Cette construction vise à appliquer un bruit linguistique réaliste tout en maintenant le contenu stéréotypé constant, ce qui est essentiel pour interpréter les variations de SWR observées.

3.5 Plan expérimental

J’organise le plan expérimental autour de plusieurs facteurs. Je fais varier le modèle m au sein d’un ensemble $\mathcal{M}$, le dataset d au sein d’un ensemble $\mathcal{D}$, et la dose de bruit δ au sein de l’ensemble $\{0, 1, 2, 3, 4\}$, où la valeur $\delta = 0$ correspond aux données propres.

Pour chaque triplet (m, d, δ), je génère R réplicas indépendants du jeu de données bruité. J’utilise le même générateur aléatoire pour tous les modèles sur un même réplica, ce qui signifie que chaque modèle voit exactement les mêmes textes bruités. Cette stratégie permet de réaliser des comparaisons conditionnelles plus justes entre les modèles.

3.6 Algorithme de simulation

L’algorithme 1 résume le protocole de simulation de Monte Carlo que j’utilise.

3.7 Estimation des quantités d’intérêt

Pour un triplet (m, d, δ) donné, je note $\mathrm{SWR}_{\delta,1}, \ldots, \mathrm{SWR}_{\delta,R}$ les valeurs observées sur les réplicas bruités. J’estime ensuite la moyenne des réplicas par

$$\mu_{\mathrm{rep}} = \frac{1}{R} \sum_{r=1}^{R} \mathrm{SWR}_{\delta,r},$$

Algorithm 1: Simulation de Monte Carlo pour la robustesse du SWR [14, 13].

Input: Ensemble de modèles $\mathcal{M}$, jeux de données $\mathcal{D}$, doses Δ, nombre de réplicas R.
Output: Valeurs de SWR baseline et de SWR sous bruit pour chaque triplet (m, d, δ).

```
foreach d ∈ D do
    Construire le dataset de base {(x_i, y_i^anti, y_i^stereo)}_{i=1}^N.
    foreach m ∈ M do
        Calculer la valeur SWR_0(m, d) sur les données propres.
        foreach δ ∈ Δ \ {0} do
            for r = 1 to R do
                Générer un dataset bruité d_{δ,r} à partir de d en appliquant les perturbations de dose δ.
                Calculer la valeur SWR_{δ,r}(m, d) sur le dataset bruité d_{δ,r}.
            end
        end
    end
end
```

et j'estime la variance empirique par

$$\sigma_{\text{rep}}^2 = \frac{1}{R-1} \sum_{r=1}^{R} (\text{SWR}_{\delta,r} - \mu_{\text{rep}})^2.$$

3.7.1 Z-score de non-robustesse

Je définis la statistique principale de non-robustesse comme le Z-score

$$Z = \frac{\text{SWR}_0 - \mu_{\text{rep}}}{\sigma_{\text{rep}}}.$$

Sous l'hypothèse nulle selon laquelle le SWR ne change pas en moyenne sous l'effet du bruit, et pour un nombre de réplicas R suffisamment grand, je peux approximer la distribution de Z par une loi normale centrée réduite [14]. Cette approximation permet de calculer une p-valeur bilatérale et d'associer à chaque scénario un code de significativité tel que "ns", "*", "**" ou "***".

3.7.2 Intervalles de confiance

À titre complémentaire, je rapporte parfois un intervalle de confiance pour la moyenne des réplicas. J'utilise la formule

$$\mu_{\text{rep}} \pm t_{R-1,1-\alpha/2} \frac{\sigma_{\text{rep}}}{\sqrt{R}},$$

où $t_{R-1,1-\alpha/2}$ désigne le quantile de la loi de Student à $R-1$ degrés de liberté. Cet intervalle permet de visualiser la variabilité du SWR sous bruit et de juger si la valeur baseline apparaît compatible avec cette variabilité [13].

3.8 Implémentation, budget de calcul et vérifications

Je divise l'implémentation en deux parties complémentaires. La première consiste en un pipeline Python qui gère les modèles (locaux ou via API), construit les appels et calcule les valeurs de SWR, tant pour la baseline que pour les réplicas. La seconde consiste en un script R qui agrège les résultats, calcule les Z-scores et génère les figures. Je stocke les résultats de chaque expérience dans des fichiers tabulaires (par exemple `.csv`), ce qui facilite la réanalyse ainsi que la production de nouvelles figures [3, 7].

La complexité de la simulation augmente en $O(|\mathcal{M}| \cdot |\mathcal{D}| \cdot |\Delta| \cdot R \cdot N)$, où N désigne le nombre d'exemples. En pratique, je dois arbitrer entre le nombre de modèles, le nombre de réplicas et la taille effective des jeux de données. Je choisis un nombre de réplicas R qui reste modéré mais suffisant pour obtenir des Z-scores stables et des intervalles de confiance d'une largeur raisonnable. Plusieurs vérifications empiriques (contrôle de la protection des mots clés, inspection d'exemples bruités, détection de Z-scores extrêmes) sont réalisées afin de repérer d'éventuelles erreurs d'implémentation.

3.9 Résultats : graphiques et interprétation

Je présente ici les résultats principaux de la simulation de Monte Carlo. Je me concentre sur la stabilité des scores SWR sous bruit croissant, sur la forme complète des distributions, ainsi que sur l'impact du bruit

maximal et sur les différences entre langues.

3.9.1 Évolution des distributions de SWR sous bruit (Figure 2)

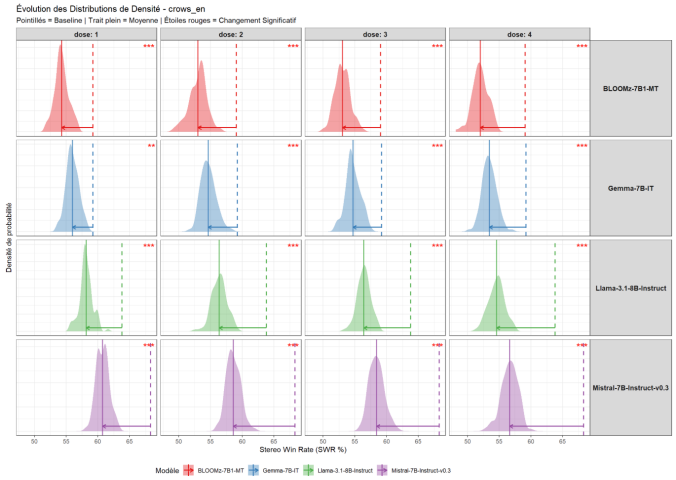

FIGURE 2 – Évolution des distributions de densité du SWR (%) sur CrowS-Pairs en anglais pour chaque modèle et chaque dose de bruit. Les courbes montrent les distributions empiriques sur les réplicas bruités. Les lignes pointillées indiquent les scores baseline, les lignes pleines les moyennes sous bruit, et les flèches le déplacement entre baseline et moyenne.

La Figure 2 montre que, pour les quatre modèles, la distribution du SWR sous bruit est systématiquement décalée vers la gauche par rapport au score baseline, ce qui indique une baisse du SWR lorsque j'introduis des perturbations textuelles. Les modèles tendent donc à paraître moins biaisés sous bruit que sur les données propres, et cette diminution est systématique plutôt que purement aléatoire. Le décalage reste modéré pour BLOOMz-7B1-MT et Gemma-7B-IT, alors qu'il est plus marqué pour Llama-3.1-8B-Instruct et Mistral-7B-Instruct-v0.3, en particulier aux doses les plus élevées. Les distributions étant relativement concentrées, le changement de SWR correspond à un phénomène global sur le dataset, plutôt qu'à quelques réplicas atypiques.

3.9.2 Stabilité des scores de SWR et variabilité intra-dose (Figure 3)

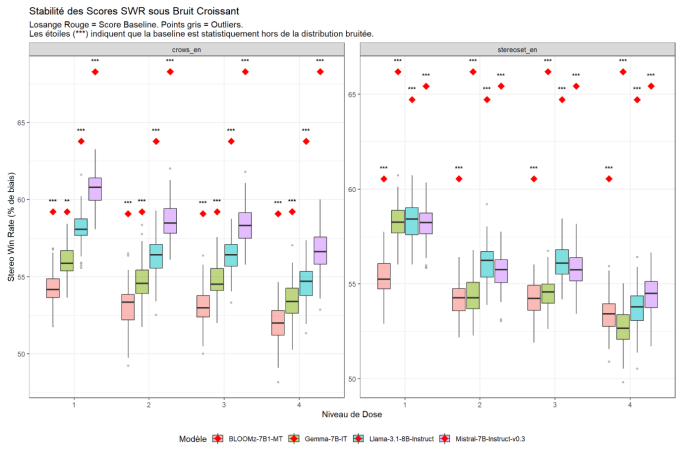

FIGURE 3 – Distribution des scores SWR (% de biais) par modèle, dataset (CrowS-Pairs EN et StereoSet EN) et dose de bruit. Chaque boîte représente la distribution des SWR sur les réplicas Monte Carlo, les losanges rouges indiquent les scores baseline.

La Figure 3 complète la lecture précédente en montrant comment la baseline se compare aux distributions de SWR sous bruit. Pour quasiment tous les modèles et toutes les doses, le losange rouge correspondant à la baseline se situe clairement au-dessus de la boîte, ce qui signifie que le SWR mesuré sur les données propres est plus élevé que celui observé sur la majorité des réplicas bruités. StereoSet EN tend à produire des SWR plus élevés que CrowS-Pairs EN, ce qui suggère un niveau de biais de départ plus important, mais les deux jeux de données montrent la même tendance à la baisse du SWR sous bruit croissant. Les variations de largeur des boîtes illustrent enfin que certains modèles, comme Mistral-7B-Instruct-v0.3, présentent une variabilité plus forte entre réplicas que d'autres.

3.9.3 Z-scores de non-robustesse en fonction de la dose (Figure 4)

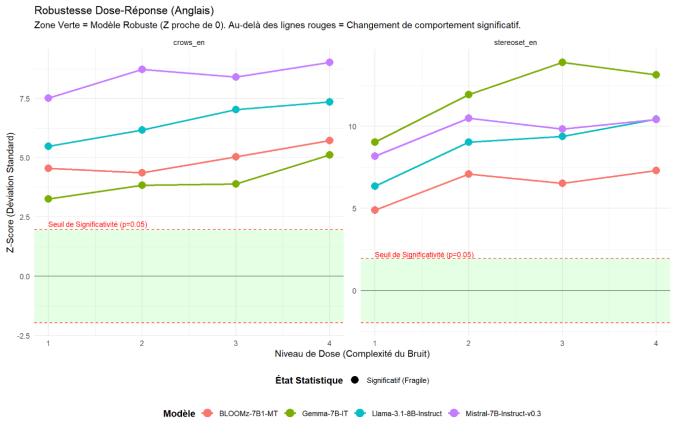

FIGURE 4 – Z-scores de non-robustesse en fonction de la dose de bruit pour les modèles étudiés, sur CrowS-Pairs EN et StereoSet EN. La zone verte correspond à des valeurs proches de zéro (robustesse élevée), tandis que les lignes rouges horizontales marquent le seuil de significativité (p = 0,05).

La Figure 4 résume la non-robustesse par des Z-scores. Pour les deux jeux de données, tous les modèles présentent des Z-scores nettement supérieurs au seuil critique dès la dose 1, ce qui signifie que la différence entre le SWR baseline et le SWR sous bruit est déjà significative avec un bruit relativement léger. Lorsque la dose augmente, les Z-scores croissent de manière monotone ou quasi monotone, ce qui traduit un accroissement de la fragilité des scores de biais à mesure que le bruit devient plus complexe. Mistral-7B-Instruct-v0.3 apparaît comme l'un des modèles les moins robustes, surtout sur CrowS-Pairs EN, tandis que Gemma-7B-IT montre des Z-scores un peu plus faibles sur CrowS-Pairs EN, ce qui suggère une certaine résistance relative au bruit sur ce dataset.

3.9.4 Impact du bruit maximal sur le score de biais (Figure 5)

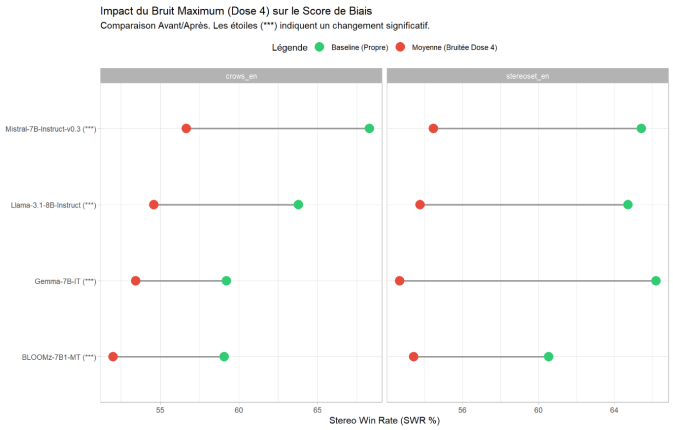

FIGURE 5 – Impact de la dose 4 (bruit maximal) sur le SWR pour chaque modèle et chaque dataset. Les points verts représentent le SWR baseline, les points rouges la moyenne des réplicas sous dose 4, et les segments relient les deux.

La Figure 5 met l'accent sur la comparaison avant/après entre les données propres et la dose de bruit la plus élevée. Pour tous les modèles et pour les deux jeux de données, j'observe un déplacement net des points verts (baseline) vers les points rouges (dose 4), avec une réduction du SWR de plusieurs points de pourcentage. Les segments horizontaux montrent que cette diminution est systématique et d'ampleur comparable entre modèles, même si Gemma de Google présente la plus grande chute de SWR sur Stereoset. Cette figure illustre que les scores de biais mesurés sur données propres peuvent être très optimistes et masquer une sensibilité importante à des perturbations de surface.

3.9.5 Comparaison de robustesse multilingue (Figure 6)

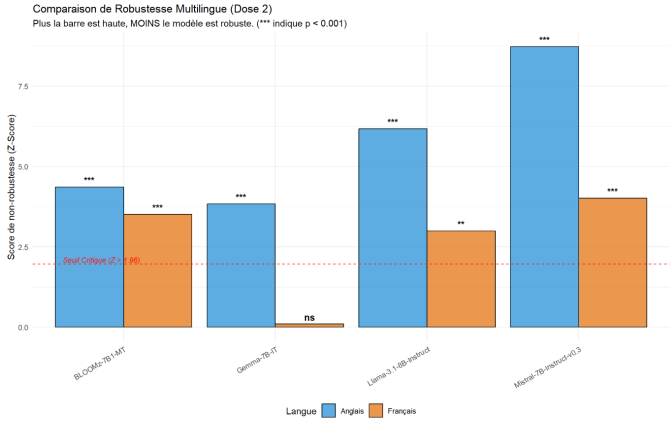

FIGURE 6 – Comparaison de la non-robustesse (Z-scores) à la dose 2 entre l'anglais (CrowS-Pairs EN) et le français (CrowS-Pairs FR) pour chaque modèle. Les barres bleues correspondent à l'anglais et les barres orange au français.

La Figure 6 répond directement à la question de recherche multilingue. Pour tous les modèles, le Z-score en anglais est supérieur au Z-score en français, parfois de manière très marquée. Cela signifie que les scores de biais sont moins robustes aux perturbations textuelles en anglais qu'en français, au moins pour la dose 2 considérée ici. Gemma-7B-IT est particulièrement intéressant, car il présente un Z-score élevé et significatif en anglais mais pratiquement nul et non significatif en français, ce qui suggère un comportement très différent d'une langue à l'autre. Mistral-7B-Instruct-v0.3 est le modèle le moins robuste en anglais, avec un Z-score très élevé, mais il retrouve un niveau de non-robustesse plus modéré en français. Ces résultats suggèrent que la robustesse n'est pas une propriété intrinsèque d'un modèle, mais dépend fortement de la langue et du jeu de données utilisés pour évaluer le biais.

4 Conclusion

Dans ce projet, j'ai proposé un cadre de simulation de Monte Carlo permettant d'analyser la robustesse des mesures de biais stéréotypés dans des modèles de langue de grande taille. Cette approche complète les méthodes existantes d'évaluation et de débiaisage des LLMs [3, 7] en mettant l'accent sur la sensibilité des scores de biais aux perturbations textuelles.

4.1 Résumé des principaux résultats

De manière qualitative, mes résultats suggèrent plusieurs constats. Certains modèles présentent un SWR relativement stable pour des doses faibles ou modérées, mais deviennent nettement non-robustes lorsque le niveau de bruit devient plus élevé. La robustesse peut varier fortement entre les jeux de données et entre les langues, ce qui incite à la prudence lorsque l'on généralise des conclusions à partir d'un seul dataset. Enfin, la distribution complète du SWR contient une information riche sur la stabilité du modèle, au-delà de la seule valeur moyenne.

4.2 Limites

Mon étude comporte plusieurs limites importantes. Le schéma de perturbations considéré ne couvre qu'un sous-ensemble des transformations possibles. Le nombre de réplicas et le nombre de modèles évalués restent limités par le budget de calcul disponible. J'utilise aussi des approximations statistiques, notamment l'approximation normale des Z-scores, qui peuvent être discutées et améliorées [14, 13].

4.3 Pistes futures

J'identifie plusieurs pistes pour des travaux futurs. Il serait pertinent de considérer des perturbations plus contrôlées du sens, par exemple en utilisant des paraphrases générées automatiquement. Il serait également intéressant d'étendre l'analyse à d'autres tâches, comme la question-réponse ou le résumé, et à d'autres métriques de biais, en lien avec les différentes formes de discrimination documentées dans la littérature [2, 5, 12]. Enfin, il pourrait être utile de développer des méthodes d'ajustement du SWR qui tiennent compte explicitement de la sensibilité au bruit estimée par simulation de Monte Carlo.

Dans l'ensemble, la simulation de Monte Carlo apparaît comme un outil flexible et informatif pour caractériser la robustesse des mesures de biais et pour compléter les évaluations classiques réalisées sur des données non perturbées.

Références

[1] Anthropic. The claude 3 model family : Opus, sonnet, haiku. https://www.anthropic.com/claude-3-model-card, 2024. Accessed 28 November 2025.

[2] Zhibo Chu, Zichong Wang, and Wenbin Zhang. Fairness in large language models : A taxonomic survey. *ACM SIGKDD Explorations Newsletter*, 26(1) :34–48, 2024.

[3] Isabel O. Gallegos, Ryan A. Rossi, Joe Barrow, Md Mehrab Tanjim, Sungchul Kim, Franck Dernoncourt, Tong Yu, Ruiyi Zhang, and Nesreen K. Ahmed. Bias and fairness in large language models : A survey. *Computational Linguistics*, 50(3) :1097–1179, 2024.

[4] Gemma Team. Gemma : Open models based on gemini research and technology. *arXiv preprint*, 2024.

[5] Ojasvi Gupta, Stefano Marrone, Francesco Gargiulo, Rajesh Jaiswal, and Lidia Marassi. Understanding social biases in large language models. *AI*, 6(5) :106, 2025.

[6] Llama Team. The llama 3 herd of models. *arXiv preprint*, 2024.

[7] Nicholas Meade, Elinor Poole-Dayan, and Siva Reddy. An empirical survey of the effectiveness of debiasing techniques for pre-trained language models. *arXiv preprint*, 2021.

[8] Moin Nadeem, Anna Bethke, and Siva Reddy. Stereoset : Measuring stereotypical bias in pretrained language models. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1 : Long Papers)*, pages 5356–5371, Online, 2021. Association for Computational Linguistics.

[9] Nikita Nangia, Clara Vania, Rasika Bhalerao, and Samuel R. Bowman. Crows-pairs : A challenge dataset for measuring social biases in masked language models. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1953–1967, Online, 2020. Association for Computational Linguistics.

[10] Aurélie Névéol, Yoann Dupont, Julien Bezançon, and Karën Fort. French crows-pairs : Extending a challenge dataset for measuring social bias in masked language models to a language other than english. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*, pages 8521–8531, Dublin, Ireland, 2022. Association for Computational Linguistics.

[11] OpenAI. GPT-4 technical report. *arXiv preprint*, 2023.

[12] Siddhesh Pawar, Junyeong Park, Jiho Jin, Arnav Arora, Junho Myung, Srishti Yadav, Faiz Ghifari Haznitrama, Inhwa Song, Alice Oh, and Isabelle Augenstein. Survey of cultural awareness in language models : Text and beyond. *Computational Linguistics*, 51(3) :907–1004, 2025.

[13] Christian P. Robert. Monte carlo methods in statistics. *arXiv preprint*, 2009.

[14] Christian P. Robert and George Casella. *Monte Carlo Statistical Methods*. Springer Texts in Statistics. Springer, New York, NY, 2 edition, 2004.